

Laporan Big Data Analytics Studi Kasus Pada Data 2015 Flight Delays and Cancellations Menggunakan Algoritma *Random Forest Classifier*

Deri¹, Moh. Alfariz², Ludy Haryanto³

¹ Program Studi Informatika, Fakultas Ilmu Komputer, Universitas Pembangunan Nasional
"Veteran" Jakarta

Email: 2310511013@mahasiswa.upnvj.ac.id¹, 2310511017@mahasiswa.upnvj.ac.id²,
2310511019@mahasiswa.upnvj.ac.id³

ABSTRAK

Penelitian ini mengintegrasikan kerangka kerja Big Data Analytics untuk memvalidasi dimensi 3V (Volume, Variety, Veracity) dan memprediksi risiko keterlambatan pesawat menggunakan dataset US Domestic Flights tahun 2015 yang memuat 5.819.079 rekaman perjalanan. Pemrosesan data dilakukan melalui pipeline Extract, Transform, Load (ETL) untuk mengatasi data skala besar. Melalui Analisis Eksploratif Data (EDA), ditemukan bahwa pemicu keterlambatan tidak didominasi oleh cuaca, melainkan oleh disfungsi manajemen rotasi armada maskapai. Untuk memprediksi delay, dikembangkan model Machine Learning menggunakan algoritma Random Forest Classifier. Model ini menghasilkan performa yang sangat solid dengan akurasi 91,63%. Analisis Feature Importance dari model tersebut mengekstraksi sebuah insight krusial: Departure Delay dan Taxi Out (waktu antrean di darat) adalah prediktor paling dominan penentu keterlambatan kedatangan. Sinergi antara evaluasi analitis dan proyeksi algoritmik ini menghasilkan instrumen taktis bagi maskapai dan otoritas bandara (ATC) untuk meminimalisir keterlambatan secara preventif dengan cara memfokuskan perbaikan efisiensi pada proses ground handling di darat.

Kata Kunci: Big Data, Delay Penerbangan, Machine Learning, Random Forest, Operasional Maskapai.

ABSTRACT

This study integrates a Big Data Analytics framework to validate the 3V dimensions (Volume, Variety, Veracity) and predict the risk of flight delays using the 2015 U.S. Domestic Flights dataset, which contains 5,819,079 flight records. Data processing was conducted via an Extract, Transform, Load (ETL) pipeline to handle large-scale data. Through Exploratory Data Analysis (EDA), it was found that the primary cause of delays was not weather but rather dysfunction in the airline's fleet rotation management. To predict delays, a machine learning model was developed using the Random Forest Classifier algorithm. This model delivered very solid performance with an accuracy of 91.63%. A Feature Importance analysis of the model revealed a crucial insight: Departure Delay and Taxi Out (ground queue time) are the most dominant predictors of arrival delays. The synergy between this analytical evaluation and algorithmic projection provides a tactical tool for airlines and airport authorities (ATC) to proactively minimize delays by focusing on improving the efficiency of ground handling processes.

Keywords: *Big Data, Flight Delays, Machine Learning, Random Forest, Airline Operations.*

1. PENDAHULUAN

Industri penerbangan komersial merupakan salah satu sektor yang tidak pernah berhenti menghasilkan data dalam jumlah masif. Setiap penerbangan yang beroperasi secara otomatis merekam puluhan informasi detail, mulai dari jadwal keberangkatan dan kedatangan, rute, maskapai, hingga durasi dan alasan spesifik jika terjadi keterlambatan. Jika diakumulasikan dalam setahun, rekaman ini dapat mencapai jutaan baris data yang mencerminkan karakteristik utama Big Data, yakni volume yang sangat besar, bentuk yang beragam, serta keakuratan yang dapat diverifikasi (Dai, 2024).

Berbagai penelitian telah dilakukan untuk menganalisis permasalahan keterlambatan penerbangan menggunakan pendekatan machine learning dan Big Data. Kilic & Sallan (2023) memanfaatkan dataset BTS Amerika Serikat untuk menganalisis jaringan bandara domestik dan membuktikan bahwa pendekatan berbasis data mampu mengungkap pola keterlambatan secara sistematis. Hatipoglu & Tosun (2024) melakukan benchmark komprehensif berbagai model machine learning untuk prediksi delay, sementara Kim & Park (2024) membuktikan bahwa faktor operasional internal maskapai terbukti lebih dominan dibanding gangguan cuaca dalam menyebabkan keterlambatan. Li et al. (2023) turut menegaskan bahwa keterlambatan pada skala tertentu memiliki risiko berantai yang tinggi dan menimbulkan kerugian ekonomi yang substansial bagi maskapai.

Meskipun demikian, sebagian besar penelitian tersebut langsung berfokus pada pemodelan prediksi tanpa terlebih dahulu memvalidasi karakteristik Big Data dari dataset yang digunakan. Penelitian yang secara spesifik membuktikan karakteristik 3V Big Data sekaligus mengeksplorasi pola operasional penerbangan domestik AS secara menyeluruh masih sangat terbatas (Kilic & Sallan, 2023; Dai, 2024).

Oleh karena itu, penelitian ini bertujuan melakukan Analisis Eksplorasi Data (EDA) pada Dataset US Domestic Flights 2015 keluaran BTS yang mencakup 5.819.079 rekaman penerbangan dengan 31 atribut, guna membuktikan karakteristik 3V Big Data sekaligus mengungkap pola-pola tersembunyi terkait keterlambatan penerbangan yang dapat dijadikan dasar pengambilan keputusan operasional bagi maskapai maupun pengelola bandara (Kim & Park, 2024; Li et al., 2023)

2. METODOLOGI

2.1 Dataset

Penelitian ini memanfaatkan dataset *US Domestic Flights 2015* yang dipublikasikan oleh *Bureau of Transportation Statistics* (BTS) dan dapat diakses secara terbuka melalui platform Kaggle. Dalam file berformat CSV berukuran 565 MB ini, tersimpan riwayat lengkap penerbangan domestik komersial di Amerika Serikat sepanjang tahun 2015. Dataset ini sangat komprehensif, mencakup lebih dari 5,8 juta (tepatnya 5.819.079) rekaman penerbangan.

Setiap baris data memiliki 31 atribut yang memetakan informasi operasional ke dalam enam dimensi utama, yaitu:

- **Dimensi Temporal:** Memuat waktu penerbangan (tahun, bulan, hari, nama hari), serta perbandingan antara jadwal dan waktu aktual keberangkatan maupun kedatangan.
- **Dimensi Identitas Penerbangan:** Mencakup kode maskapai, nomor penerbangan, dan nomor ekor pesawat (*tail number*).
- **Dimensi Geografis:** Mengidentifikasi bandara asal dan bandara tujuan.
- **Dimensi Operasional:** Merekam jarak tempuh, waktu mengudara, total waktu tempuh, serta waktu manuver pesawat di darat (*taxi-in* dan *taxi-out*).
- **Dimensi Keterlambatan (*Delay*):** Merinci durasi *delay* pada saat keberangkatan dan kedatangan, beserta akar penyebabnya (faktor sistem udara, maskapai, cuaca, keterlambatan pesawat sebelumnya, atau keamanan).
- **Dimensi Status:** Mencatat status pembatalan, pengalihan rute (*diverted*), dan alasan spesifik jika terjadi pembatalan.

2.2 Alat dan Lingkungan Penelitian


Seluruh rangkaian analisis dalam riset ini dieksekusi menggunakan bahasa pemrograman Python (versi 3.10) di dalam ekosistem Google Colaboratory (Colab). Lingkungan berbasis *cloud* ini dipilih karena menyediakan kapasitas memori yang mumpuni untuk memproses sampel data skala besar, sekaligus sangat praktis karena tidak memerlukan konfigurasi infrastruktur tambahan.

Untuk mendukung komputasinya, penelitian ini mengandalkan beberapa *library* utama:

- **pandas** untuk manipulasi dan analisis data tabular.
- **NumPy** untuk mempercepat operasi komputasi numerik.
- **Matplotlib** dan **Seaborn** untuk merancang visualisasi data yang intuitif.
- **os** untuk keperluan manajemen direktori dan file.

2.3 Proses *Extract, Transform, Load* (ETL)

Pengolahan data mentah menjadi data siap analisis dilakukan melalui *pipeline* ETL dengan tahapan sebagai berikut:



Gambar 1. Arsitektur Pipeline Big Data Analytics

2.3.1 Extract

Data CSV dimuat ke dalam lingkungan kerja menggunakan fungsi `pd.read_csv()` dari *library* *pandas*. Menyadari besarnya volume data asli dan keterbatasan alokasi memori di Colab, proses ekstraksi ini menggunakan teknik *sampling* sebanyak 300.000 baris pertama (sekitar 3,4% dari total populasi) melalui parameter `nrows`. Sebelum data dimuat sepenuhnya,

pengecekan awal terhadap ukuran file dan total baris tetap dilakukan untuk memahami skala utuh dari dataset.

2.3.2 Transform

Fase ini merupakan inti pembersihan data, yang dibagi menjadi empat langkah operasional:

- **Penanganan Data Kosong (*Missing Values*):** Dilakukan secara logis sesuai konteks kolom. Nilai *null* pada lima kolom penyebab *delay* diubah menjadi angka 0 (karena berarti tidak ada *delay* dari faktor tersebut). Kolom CANCELLATION_REASON diisi dengan "N/A" untuk penerbangan yang beroperasi normal. Terakhir, baris data yang kehilangan informasi waktu operasional utamanya dihapus, karena hal ini biasanya menandakan penerbangan dibatalkan tanpa catatan aktual yang memadai.
- **Penyesuaian Tipe Data:** Memastikan seluruh data numerik telah berformat *float* atau *integer* agar perhitungan matematis dapat berjalan lancar.
- **Rekayasa Fitur (*Feature Engineering*):** Untuk memperkaya analisis, diciptakan lima kolom baru: DAY_NAME (hari), MONTH_NAME (bulan), DELAY_CATEGORY (pengelompokan *delay* berdasarkan durasi), IS_DELAYED (indikator *delay* biner yang merujuk pada standar 15 menit dari FAA), dan TOTAL_DELAY_CAUSE (akumulasi waktu dari semua faktor penyebab).
- **Pembersihan Duplikasi:** Memindai dan menghapus baris data yang identik.

2.3.3 Load

Setelah data berhasil dibersihkan dan diformat ulang, *dataframe* akhir disimpan kembali ke dalam format CSV dengan nama *flights_cleaned.csv*. File keluaran inilah yang kemudian menjadi fondasi dasar untuk tahapan eksplorasi maupun pemodelan lebih lanjut.

2.4 Metode Analisis EDA

Untuk mengungkap wawasan tersembunyi dari data yang telah bersih, proses EDA dijalankan secara sistematis melalui lima pendekatan:

1. **Validasi Kualitas Data:** Memastikan ulang kebersihan data dari *missing values*, duplikasi, dan ketepatan tipe data.
2. **Statistik Deskriptif:** Mengkalkulasi nilai rata-rata, median, standar deviasi, hingga titik nilai terendah dan tertinggi pada variabel numerik.
3. **Analisis Pola (*Visualisasi*):** Memetakan sebaran *delay* untuk melihat trennya berdasarkan maskapai, siklus bulan dan hari, serta mendistribusikan akar penyebab keterlambatan menggunakan grafik.
4. **Analisis Korelasi:** Memanfaatkan *Heatmap Pearson Correlation* untuk mendeteksi seberapa kuat hubungan atau pengaruh antar-variabel numerik dalam dataset.
5. **Pembuktian Karakteristik *Big Data*:** Melakukan validasi kuantitatif guna membuktikan bahwa dataset ini benar-benar mewakili tiga pilar utama *Big Data*, yaitu *Volume*, *Variety*, dan *Veracity*.

3. HASIL PEMBAHASAN

3.1 Analisis Data Quality

Tabel 1 menyajikan ringkasan hasil evaluasi kualitas data pada dataset *US Domestic Flights 2015*. Sesuai dengan batasan komputasi yang telah diuraikan sebelumnya, analisis ini berfokus pada sampel data sebanyak 300.000 baris, yang merepresentasikan sekitar 3,4% dari total populasi yang berjumlah 5.819.079 rekaman penerbangan.


Tabel 1. Ringkasan Data Quality Dataset US Domestic Flights 2015

Parameter	Nilai
Total baris (sampel)	300.000
Total baris (full dataset)	5.819.079
Total kolom	31
Kolom dengan missing values	17 dari 31 kolom
Total sel null (sampel)	~949.605 sel (15,32%)
Kolom dengan null tertinggi	CANCELLATION_REASON (98,1%)
Kolom null kedua tertinggi	Kolom penyebab delay (75,9%)
Data duplikat	0 (tidak ada)
Null setelah cleaning (kolom utama)	0%

Berdasarkan pemindaian awal terhadap 31 kolom dalam dataset, teridentifikasi 17 kolom yang memiliki *missing values* (data kosong). Namun, setelah ditelaah lebih lanjut, kekosongan data ini sepenuhnya valid dan dapat dijelaskan secara kontekstual. Persentase *null* tertinggi, misalnya, ditemukan pada kolom CANCELLATION_REASON yang mencapai 98,1%. Angka yang ekstrem ini sebenarnya sangat wajar, karena atribut tersebut secara logis hanya akan terisi jika sebuah penerbangan berstatus batal. Mengingat tingkat pembatalan penerbangan secara keseluruhan hanya berkisar di angka 2,39%, kekosongan data pada mayoritas baris di kolom ini adalah kondisi yang normal.

Pola logis serupa juga terlihat pada kelima atribut penyebab keterlambatan, yaitu AIR_SYSTEM_DELAY, WEATHER_DELAY, AIRLINE_DELAY, LATE_AIRCRAFT_DELAY, dan SECURITY_DELAY. Kelima kolom ini masing-masing mencatatkan *missing values* di kisaran 75,9%. Secara semantik, hal ini dapat diterima karena rincian durasi penyebab *delay* tentu tidak akan dicatat pada penerbangan yang beroperasi tepat waktu.

Di sisi lain, atribut operasional utama seperti ELAPSED_TIME, AIR_TIME, ARRIVAL_DELAY, dan DEPARTURE_DELAY mencatatkan tingkat kekosongan yang sangat minim, yakni hanya sekitar 1 hingga 2 persen. Absennya data pada persentase kecil ini berkorelasi langsung dengan insiden penerbangan yang dibatalkan, sehingga wajar bila data durasi aktualnya tidak terekam. Selain itu, pengecekan integritas data juga mengonfirmasi bahwa tidak ada satu pun baris data yang terduplikasi (*duplicate*) dalam sampel yang dianalisis.



Gambar 2. Perbandingan Missing Values Sebelum dan Sesudah Cleaning

Keberhasilan dalam menangani *missing values* melalui proses *cleaning* ini sekaligus menjadi pembuktian empiris terhadap salah satu karakteristik utama *Big Data*, yaitu **Veracity** (Keabsahan/Keandalan). Dataset yang telah tervalidasi, bersih dari duplikasi, dan memiliki pola data kosong yang dapat dijelaskan secara rasional ini menunjukkan tingkat keterpercayaan yang sangat tinggi. Kondisi ideal ini menjadikan dataset BTS 2015 sangat layak dan andal untuk dijadikan fondasi dalam analisis lanjutan maupun pemodelan yang lebih kompleks (Wang et al., 2022; Hatipoglu et al., 2022).

3.2 Statistik Deskriptif

Tabel 2 memaparkan rangkuman statistik deskriptif untuk enam variabel numerik krusial di dalam dataset yang telah melalui tahap pembersihan (*cleaning*).

Tabel 2. Statistik Deskriptif Variabel Numerik Utama

Variabel	Mean	Std	Min	Max
DEPARTURE_DELAY (mnt)	12,701	39.67	-47.00	1604.00
ARRIVAL_DELAY (mnt)	9.27	42.66	-76.00	1593.00
DISTANCE (mil)	813.08	599.99	31.00	4983.00
AIR_TIME (mnt)	115.93	73.58	8.00	676.00
TAXI_OUT (mnt)	17.06	10.63	1.00	176.00
TAXI_IN (mnt)	8.18	8.04	1.00	179.00

Evaluasi statistik deskriptif ini memperlihatkan pola sebaran data yang menarik, terutama pada aspek waktu operasional penerbangan. Untuk variabel DEPARTURE_DELAY dan ARRIVAL_DELAY, rata-rata keterlambatannya masing-masing berada di angka **12,70 menit** dan **9,27 menit**. Sepintas, angka rata-rata ini tampak tergolong wajar dan moderat. Namun, jika disandingkan dengan rekor maksimumnya, terlihat adanya rentang ketimpangan yang sangat mencolok. Keterlambatan paling parah bahkan menyentuh angka yang ekstrem, yakni **1.604 menit** untuk jadwal keberangkatan dan **1.593 menit** untuk kedatangan.


Jarak yang terlampau jauh antara nilai rata-rata dan batas maksimum ini menjadi indikator kuat bahwa distribusi data tersebut cenderung condong ke kanan (*right-skewed*). Kesimpulan ini semakin solid dengan ditemukannya nilai minimum yang negatif pada kedua variabel, yaitu **-47 menit** (berangkat lebih awal) dan **-76 menit** (tiba lebih awal). Pada praktiknya, data ini menegaskan bahwa mayoritas penerbangan sesungguhnya beroperasi tepat waktu, bahkan tak jarang mendahului jadwal aslinya. Akan tetapi, kemunculan beberapa insiden keterlambatan yang luar biasa lama sebagai pencilan (*outlier* ekstrem) telah mendongkrak nilai rata-rata keseluruhan secara signifikan.

Besarnya fluktuasi dan ketidakpastian operasional di lapangan juga tergambar jelas dari tingginya standar deviasi pada kedua variabel keterlambatan tersebut (**39,67** dan **42,66**

menit). Variabilitas berskala lebar ini tidak hanya terjadi pada dimensi waktu, tetapi juga pada variabel DISTANCE (jarak tempuh). Dengan rata-rata jarak **813,08 mil** dan standar deviasi **599,99 mil**, dataset ini terbukti mampu merekam seluruh spektrum keberagaman rute domestik di Amerika Serikat secara utuh dimulai dari penerbangan regional jarak pendek (31 mil) hingga rute panjang lintas benua yang mencapai 4.983 mil.

	DEPARTURE_DELAY	ARRIVAL_DELAY	DISTANCE	AIR_TIME	TAXI_OUT	TAXI_IN
count	293634.00	293634.00	293634.00	293634.00	293634.00	293634.00
mean	12.70	9.27	813.08	113.65	16.54	7.72
std	39.67	42.66	599.99	72.30	9.57	6.81
min	-47.00	-76.00	31.00	8.00	1.00	1.00
25%	-4.00	-11.00	370.00	60.00	11.00	4.00
50%	-1.00	-2.00	647.00	95.00	14.00	6.00
75%	13.00	14.00	1055.00	145.00	19.00	9.00
max	1604.00	1593.00	4983.00	676.00	176.00	179.00

Kategori Delay Kedatangan



Gambar 3. Statistik Deskriptif dan Boxplot Variabel Numerik Utama


Lebih lanjut, pembedahan data berdasarkan klasifikasi durasi *delay* memperlihatkan bahwa lebih dari separuh jadwal (**55,7%**) sukses mendarat tepat waktu (*arrival delay* 0 menit atau kurang). Sisanya terdistribusi menjadi *delay* ringan (1 hingga 15 menit) sebanyak **20,5%**, *delay* sedang (16 hingga 60 menit) sebesar **16,2%**, dan *delay* parah (di atas 60 menit) sebesar **7,6%**.

Jika diakumulasikan, gabungan antara *delay* sedang dan parah menyumbang hampir **24%** (tepatnya 23,8%) dari total penerbangan. Dari kacamata manajemen operasional, persentase ini sangatlah krusial. Keterlambatan pada skala waktu tersebut memiliki risiko berantai yang tinggi, mulai dari kacaunya jadwal penumpang untuk penerbangan lanjutan (*connecting flight*) hingga timbulnya kerugian ekonomi yang substansial bagi maskapai (Bisandu & Moulitsas, 2023; Li et al., 2023).

3.3 Analisis Diagnosis

3.3.1 Perbandingan Delay per Maskapai

Evaluasi terhadap rata-rata durasi *delay* kedatangan menyingkap adanya ketimpangan performa ketepatan waktu (*on-time performance*) yang cukup mencolok di antara berbagai operator penerbangan. Visualisasi pada Gambar 3 memetakan secara komprehensif perbandingan rata-rata keterlambatan, sekaligus persentase jadwal penerbangan yang meleset dari target untuk masing-masing maskapai selama tahun 2015.



Gambar 4. Rata-rata Delay Kedatangan dan Persentase Penerbangan Terlambat per Maskapai

Berdasarkan pemetaan performa tiap maskapai, **Envoy Air** tercatat sebagai operator dengan kinerja ketepatan waktu terendah. Rata-rata *delay* kedatangannya menyentuh angka tertinggi yakni **24,8 menit**, beriringan dengan proporsi keterlambatan penerbangan (>15 menit) yang mencapai level ekstrem di angka **40,0%**. Posisi ini disusul secara ketat oleh **Frontier Airlines**, yang mencatatkan rata-rata *delay* **23,6 menit** dengan tingkat keterlambatan jadwal sebesar **36,0%**. Tingginya rekor keterlambatan pada kedua maskapai regional ini sangat berkaitan erat dengan model operasional mereka yang berfokus pada jaringan rute pendek. Karakteristik bisnis ini menuntut jadwal rotasi pesawat yang sangat padat dengan jeda transit minim. Akibatnya, ekosistem operasional mereka menjadi sangat rentan; satu keterlambatan minor di awal hari akan dengan mudah memicu efek domino yang mengacaukan seluruh rantai penerbangan berikutnya pada hari yang sama.

Sebaliknya, **Alaska Airlines** dan **Delta Air Lines** menunjukkan performa paling superior dalam menekan durasi keterlambatan, dengan rata-rata *delay* kedatangan yang berhasil ditekan hingga nyaris nol, yakni masing-masing hanya **0,4 menit** dan **0,5 menit**.

Jika ditinjau dari proporsi frekuensi keterlambatannya, **Hawaiian Airlines** memimpin sebagai maskapai paling tepat waktu dengan persentase penerbangan terlambat (>15 menit) paling rendah di angka **13,4%** (dan rata-rata durasi *delay* **4,3 menit**). Posisi ini disusul oleh **Delta (14,5%)** dan **Alaska (14,7%)**. Pencapaian impresif Hawaiian Airlines ini sangat diuntungkan oleh karakteristik rute operasionalnya yang terisolasi dari kepadatan lalu lintas udara daratan utama Amerika Serikat, sehingga mereka terhindar dari imbas keterlambatan berantai yang kerap melumpuhkan operasional di hub-hub besar.

Di sisi tengah spektrum, **Southwest Airlines** menampilkan efisiensi operasional yang patut disorot. Meskipun berstatus sebagai maskapai dengan volume penerbangan komersial yang masif, mereka mampu mempertahankan rata-rata *delay* di angka yang moderat yakni **6,9 menit**, dengan persentase frekuensi keterlambatan **22,8%**. Angka ini membuktikan solidnya manajemen operasional Southwest dalam menangani manuver lalu lintas skala besar tanpa mengorbankan kualitas ketepatan waktu secara signifikan.

3.3.2 Tren Delay Bulanan dan Volume Penerbangan

Evaluasi tren secara bulanan menyingkap adanya dua siklus puncak keterlambatan sepanjang tahun 2015, di mana masing-masing dipicu oleh karakteristik penyebab yang berbeda. Puncak pertama terjadi pada bulan Februari; tingginya rata-rata *delay* pada bulan ini memiliki korelasi yang erat dengan terjangan cuaca musim dingin ekstrem di kawasan timur dan tengah Amerika Serikat. Puncak kedua berlangsung pada rentang Juni hingga Juli. Periode ini bertepatan dengan momentum liburan musim panas, yang memicu lonjakan volume penerbangan hingga ke titik maksimalnya. Kepadatan jadwal inilah yang kemudian memperparah efek *delay* berantai.


Sebaliknya, bulan September dan Oktober mencatatkan angka *delay* paling rendah. Kedua bulan tersebut merupakan masa transisi pasca-liburan, sehingga volume penerbangan

kembali moderat yang didukung pula oleh kondisi cuaca yang lebih stabil. Pola fluktuasi musiman ini sejalan dengan berbagai temuan riset terdahulu yang juga menganalisis lalu lintas udara domestik AS (Wang et al., 2022; Saurabh et al., 2024).

3.3.3 Pola Delay Berdasarkan Hari dalam Seminggu


Berdasarkan analisis pergerakan mingguan, hari **Minggu** tercatat sebagai hari dengan rata-rata keterlambatan kedatangan paling tinggi, yakni menyentuh **14,8 menit**. Posisi ini disusul oleh hari **Senin** di angka **11,7 menit**. Di ujung spektrum lainnya, hari **Rabu** menjadi hari yang paling tepat waktu dengan rata-rata *delay* terendah di angka **5,6 menit**, jauh di bawah rata-rata keseluruhan yang berada di angka **9,1 menit**.

Ketimpangan pola ini menjadi sangat rasional jika dijelaskan melalui mekanisme akumulasi operasional. Keterlambatan minor yang terjadi di siklus awal harian akan terus terakumulasi layaknya efek bola salju dan mencapai titik kritisnya pada hari-hari dengan kepadatan lalu lintas tertinggi, yakni hari Minggu. Di sisi lain, hari Rabu yang berada di tengah pekan cenderung lebih stabil operasionalnya, sehingga jadwal penerbangan jauh lebih teratur dan penumpukan *delay* dapat diminimalisir dengan baik.



Gambar 5. Rata-rata Delay Berdasarkan Hari dalam Seminggu

3.3.4 Analisis Akar Penyebab Delay



Gambar 6. Rata-rata Kontribusi Penyebab Delay pada Penerbangan yang Terlambat

Apabila dibedah berdasarkan akar masalahnya, *Late Aircraft Delay* (keterlambatan rotasi pesawat dari rute sebelumnya) muncul sebagai kontributor penyumbang waktu *delay* terbesar, dengan rata-rata **13,5 menit**. Fakta ini mengindikasikan adanya kelemahan sistemik dalam manajemen rotasi armada maskapai, di mana kendala keterlambatan pada rute awal secara otomatis menjalar ke jadwal-jadwal selanjutnya.


Faktor internal maskapai (*Airline Delay*) menempati posisi kedua dengan durasi **10,1 menit**, disusul oleh masalah pada sistem udara (*Air System Delay*) sebesar **7,4 menit**—yang umumnya bermuara dari padatnya lalu lintas udara dan ketatnya manajemen slot oleh otoritas bandara. Menariknya, gangguan cuaca (*Weather Delay*) ternyata hanya menyumbang rata-rata **1,7 menit**, jauh lebih minim dibandingkan dengan asumsi umum publik. Sementara itu, masalah keamanan (*Security Delay*) persentasenya tetap berada di angka **0,0 menit**. Komposisi penyebab ini selaras dengan temuan riset Kim & Park (2024), yang menegaskan bahwa faktor kelemahan operasional maskapai menyumbang andil yang jauh lebih masif terhadap *delay* ketimbang gangguan cuaca eksternal.

3.3.5 Analisis Korelasi Antar Variabel

Pengujian menggunakan *Heatmap Pearson Correlation* berhasil memetakan hubungan linear antarvariabel numerik dalam dataset. Variabel *DEPARTURE_DELAY* dan *ARRIVAL_DELAY*, misalnya, menunjukkan korelasi positif yang sangat kuat dengan nilai $r = 0,95$. Angka ini secara matematis memvalidasi logika di lapangan bahwa keterlambatan saat keberangkatan hampir pasti akan menjalar hingga kedatangan, kecuali jika berhasil dikompensasi oleh kecepatan ekstra selama di udara.

Selain itu, variabel AIR_TIME terbukti memiliki korelasi positif yang nyaris sempurna terhadap variabel DISTANCE dengan nilai $r = 0,98$. Hal ini memvalidasi keabsahan data fisik penerbangan secara rasional.

Jika ditinjau dari faktor penyebabnya, LATE_AIRCRAFT_DELAY ($r = 0,69$) dan AIRLINE_DELAY ($r = 0,63$) menjadi dua variabel yang memiliki pengaruh korelasi terkuat terhadap DEPARTURE_DELAY. Di sisi lain, variabel TAXI_OUT memperlihatkan korelasi moderat terhadap AIR_SYSTEM_DELAY ($r = 0,40$) serta ARRIVAL_DELAY dengan nilai $r = 0,22$. Pola ini menandakan bahwa durasi manuver pesawat di darat sebelum lepas landas merupakan salah satu indikator awal yang berkontribusi langsung pada keterlambatan sistem penerbangan dan waktu kedatangan. Konsistensi pola korelasi yang sejalan dengan hukum operasional dan fisika penerbangan ini semakin mengukuhkan aspek *Veracity* dari dataset yang digunakan.



Gambar 7. Korelasi Antar Variabel Numerik Penerbangan

3.3.6 Pembuktian 3V Big Data

Menilik seluruh rangkaian proses dan hasil analisis yang telah dipaparkan, dataset *US Domestic Flights 2015* secara empiris memenuhi tiga dari lima pilar karakteristik *Big Data*, sebagaimana direkapitulasi pada Tabel 3.

Tabel 3. Pembuktian 3V Karakteristik Big Data

Dimensi	Indikator	Nilai / Bukti
VOLUME	Ukuran file	565 MB (592 MB uncompressed)
VOLUME	Total rekaman	5.819.079 penerbangan
VOLUME	Total atribut	31 kolom per rekaman
VOLUME	Perbandingan	Melampaui batas maksimum Excel (~1 juta baris)
VARIETY	Jumlah kolom	31 kolom, 6 dimensi operasional berbeda
VARIETY	Tipe data	float64 (15 kolom), int64 (11 kolom), object (5 kolom)
VARIETY	Sumber data	Multi-sistem: ATC, maskapai, bandara, cuaca
VERACITY	Missing values	Seluruhnya dapat dijelaskan secara kontekstual
VERACITY	Duplikasi	0 duplikat ditemukan
VERACITY	Konsistensi	Korelasi antar variabel sesuai hukum fisika penerbangan

- Volume:** Dengan ukuran file mencapai 565 MB dan merekam 5.819.079 baris data, skala dataset ini dengan mutlak telah melampaui limitasi pemrosesan perangkat lunak konvensional. Sebagai perbandingan, *spreadsheet* seperti Microsoft Excel memiliki batas maksimal penampungan sekitar satu juta baris. Oleh karena itu, pengolahannya mutlak membutuhkan *framework* khusus seperti pandas yang dikombinasikan dengan teknik *sampling* strategis, maupun pemanfaatan platform komputasi terdistribusi (Dai, 2024; Hatipoglu & Tosun, 2022).
- Variety (Keberagaman):** Pilar ini dibuktikan melalui kayanya tipe dan dimensi data yang dilebur menjadi satu kesatuan tabel. Dataset ini memadukan data numerik kontinu (seperti durasi *delay* dan jarak), numerik diskrit (nomor penerbangan, urutan hari), hingga data kategorikal (kode identitas maskapai dan bandara). Kompleksitas ini merepresentasikan data yang diserap dari bermacam-macam ekosistem sistem yang berbeda, yaitu sistem *Air Traffic Control* (ATC), pencatatan internal maskapai, hingga arsitektur manajemen bandara.
- Veracity (Keandalan):** Aspek keandalan ini berhasil divalidasi pada tahap uji kualitas data (Bab 3.1). Seluruh ketidaklengkapan (*missing values*) di dalam dataset terbukti dapat dipertanggungjawabkan secara kontekstual, data terbebas dari anomali duplikasi, serta memiliki pola korelasi matematis antar-variabel yang sepenuhnya mencerminkan konsistensi kondisi di dunia nyata.

3.4 Diagnosis dan Predictive

Tabel 4. Hasil Random Forest Classification


	precision	recall	f1-score	support
0 (Tidak Terlambat)	0.92	0.96	0.94	16191
1 (Terlambat)	0.92	0.82	0.87	7957
accuracy			0.92	24148
macro avg	0.92	0.89	0.90	24148
weighted avg	0.92	0.92	0.92	24148

Berdasarkan hasil pengujian menggunakan algoritma *Random Forest Classifier*, model klasifikasi yang dibangun menunjukkan performa yang sangat baik dalam mengidentifikasi risiko keterlambatan kedatangan penerbangan (*ARRIVAL_DELAY*). Model berhasil mencapai tingkat akurasi sebesar 91,63% dari total 24.148 data uji, yang menandakan bahwa sebagian besar jadwal penerbangan berhasil diprediksi dengan benar. Pada kelas 0 (Tidak Terlambat) diperoleh nilai *precision* 0,9164, *recall* 0,9629, dan *f1-score* 0,9391, sedangkan pada kelas 1 (Terlambat) diperoleh *precision* 0,9159, *recall* 0,8213, dan *f1-score* 0,8660. Hasil ini menunjukkan bahwa model memiliki kemampuan yang andal dan relatif seimbang dalam mengenali kedua kategori data, meskipun sedikit lebih sensitif dalam mendeteksi kelas mayoritas (tepat waktu).

Selain itu, nilai *macro average* (0,9026) dan *weighted average* (0,9150) yang berada pada angka yang sangat tinggi menunjukkan bahwa performa model cukup konsisten dan tidak mengalami ketimpangan yang signifikan antar kelas, kendati terdapat perbedaan jumlah *support* pada distribusi target (imbalanced). Dengan jumlah pohon (*n_estimators*) sebanyak 100 dan kedalaman (*max_depth*) 10, metode *Random Forest* dapat dinilai sangat efektif sebagai pendekatan andal dalam proses klasifikasi penerbangan berisiko terlambat.

3.5 Analisis Aturan Model (*Feature Importance*) dan *Insight*

Untuk memahami bagaimana algoritma *Random Forest* membedakan penerbangan yang tepat waktu dan terlambat, dilakukan ekstraksi aturan keputusan (*decision rules*) melalui perhitungan *Feature Importance*. Grafik di bawah ini mengurutkan variabel mana yang paling kuat pengaruhnya dalam menentukan hasil prediksi.



Gambar 8. Tingkat Kepentingan Fitur (*Feature Importance*) pada Model Random Forest

Berdasarkan visualisasi pada Gambar 8, variabel **Departure Delay** dan **Taxi Out** (waktu manuver pesawat di darat sebelum lepas landas) mendominasi sebagai fitur yang paling penting dalam model klasifikasi ini, mengalahkan faktor maskapai (*Airline*) maupun siklus waktu (*Month* dan *Day of Week*).

Insight dari pola ini adalah:

- 1. Efek Domino Keterlambatan:** Model secara algoritmik membuktikan bahwa keterlambatan bersifat linier dan kausal. Keterlambatan jadwal saat lepas landas (*Departure Delay*) hampir mustahil untuk dikompensasi hanya dengan menambah kecepatan selama mengudara.
- 2. Krusialnya Efisiensi Darat:** Tingginya bobot fitur *Taxi Out* memberikan *insight* strategis bagi manajemen operasional. Waktu yang dihabiskan pesawat untuk mengantre di jalur taksi menuju landasan pacu adalah indikator kuat terjadinya *delay* kedatangan.

Oleh karena itu, instrumen taktis yang paling efektif bagi maskapai dan otoritas bandara (ATC) bukanlah sekadar memperbaiki jadwal penerbangan, melainkan mempercepat proses *ground handling* dan meminimalisir penumpukan antrean pesawat di darat sebelum lepas landas. Jika *Taxi Out* dapat ditekan, probabilitas pesawat tiba tepat waktu akan meningkat secara signifikan.

4. KESIMPULAN

Penelitian ini mengonfirmasi bahwa dataset US Domestic Flights 2015 memenuhi karakteristik 3V Big Data (Volume, Variety, Veracity). Berdasarkan analisis yang dilakukan, penyebab utama keterlambatan penerbangan ternyata didominasi oleh faktor internal maskapai, khususnya kendala pada rotasi pesawat, bukan akibat faktor cuaca seperti asumsi pada umumnya. Keterlambatan ini terbukti memiliki efek berantai yang secara langsung mengacaukan jadwal penerbangan selanjutnya yang menggunakan pesawat yang sama, dengan lonjakan puncak keterlambatan terjadi pada bulan Februari serta periode liburan bulan Juni-Juli. Sebagai langkah antisipasi, penerapan algoritma *Random Forest Classifier* menunjukkan hasil yang sangat memuaskan dengan akurasi prediksi mencapai 91,63%. Lebih lanjut, ekstraksi aturan dari model tersebut memberikan *insight* baru bahwa ketepatan waktu lepas landas (*Departure Delay*) dan efisiensi waktu manuver di darat (*Taxi Out*) adalah kunci utama penentu keterlambatan. Temuan komprehensif ini menjadikan model klasifikasi tersebut sangat layak dan dapat diandalkan sebagai instrumen taktis oleh maskapai maupun otoritas bandara (ATC) untuk memitigasi risiko keterlambatan secara proaktif, terutama dengan memfokuskan perbaikan operasional pada proses penanganan di darat (*ground handling*).

DAFTAR RUJUKAN

- [1] Afrane, M. D., Xu, Y., Li, L., & Wang, K. (2025). Flight Delay Prediction Using Random Forest with Enhanced Feature Engineering. IEEE SoutheastCon 2025, 1055-1056. <https://doi.org/10.1109/southeastcon56624.2025.10971443>
- [2] AlBassam, S. A. A., & AlShahrani, D. N. (2025). Flight delay prediction: Evaluating machine learning algorithms for enhanced accuracy. PLOS ONE. <https://doi.org/10.1371/journal.pone.0335141>
- [3] Bisandu, D. B., & Moulitsas, I. (2023). A Deep BiLSTM Machine Learning Method for Flight Delay Prediction Classification. Journal of Aviation/Aerospace Education and Research, 32(2). <https://doi.org/10.58940/2329-258X.1992>
- [4] Cai, K., Li, Y., Fang, Y.-P., & Zhu, Y. (2022). A Deep Learning Approach for Flight Delay Prediction Through Time-Evolving Graphs. IEEE Transactions on Intelligent Transportation Systems, 23(8), 11397-11407. <https://doi.org/10.1109/tits.2021.3103502>
- [5] Dai, M. (2024). A hybrid machine learning-based model for predicting flight delay through aviation big data. Scientific Reports, 14, 4603. <https://doi.org/10.1038/s41598-024-55217-z>
- [6] Deng, W., Li, K., & Zhao, H. (2024). A Flight Arrival Time Prediction Method Based on Cluster Clustering-Based Modular With Deep Neural Network. IEEE Transactions on Intelligent Transportation Systems, 25(6), 6238-6247. <https://doi.org/10.1109/tits.2023.3338251>
- [7] Flight Delay Prediction Using Hybrid Machine Learning: A Case Study of Major US Airlines. (2024). arXiv. <https://arxiv.org/abs/2409.00607>
- [8] Hatipoglu, I., Tosun, O., & Tosun, N. (2022). Flight delay prediction based with machine learning. LogForum, 18(1), 97-107. <https://doi.org/10.17270/J.LOG.2022.655>
- [9] Hatipoglu, I., & Tosun, O. (2024). Predictive Modeling of Flight Delays at an Airport Using Machine Learning Methods. Applied Sciences, 14(13), 5472. <https://doi.org/10.3390/app14135472>
- [10] Kilic, K., & Sallan, J. M. (2023). Study of Delay Prediction in the US Airport Network. Aerospace, 10(4), 342. <https://doi.org/10.3390/aerospace10040342>
- [11] Kim, S., & Park, E. (2024). Prediction of flight departure delays caused by weather conditions adopting data-driven approaches. Journal of Big Data, 11(1). <https://doi.org/10.1186/s40537-023-00867-5>
- [12] Li, Q., Guan, X., & Liu, J. (2023). A CNN-LSTM framework for flight delay prediction. Expert Systems with Applications, 227, 120287. <https://doi.org/10.1016/j.eswa.2023.120287>
- [13] Liu, J., Zhao, J., Lu, Y., & Wu, Y. (2022). Flight Delay Prediction Method Based on LSTM. 2022 International Conference on Automation, Robotics and Computer Engineering (ICARCE). <https://doi.org/10.1109/ICARCE55724.2022.10046519>
- [14] Qu, J., Wu, S., & Zhang, J. (2023). Flight Delay Propagation Prediction Based on Deep Learning. Mathematics, 11(3), 494. <https://doi.org/10.3390/math11030494>
- [15] Saurabh, P., et al. (2024). Deciphering Air Travel Disruptions: A Machine Learning Approach. arXiv:2408.02802. <https://arxiv.org/abs/2408.02802>

- [16] Tijil, et al. (2024). Flight Delay Prediction Using Machine Learning Techniques. IEEE. <https://doi.org/10.1109/ic2pct60090.2024.10486482>
- [17] Wang, F., Bi, J., Xie, D., & Zhao, X. (2022). Flight delay forecasting and analysis of direct and indirect factors. IET Intelligent Transport Systems, 16(7), 890-907. <https://doi.org/10.1049/itr2.12183>
- [18] Wang, Z., Liao, C., Hang, X., Li, L., Delahaye, D., & Hansen, M. (2022). Distribution prediction of strategic flight delays via machine learning methods. Sustainability, 14(22), 15180. <https://doi.org/10.3390/su142215180>
- [19] Yuan, Y., Wang, Y., & Lai, C. S. (2025). Multi-Attribute Data-Driven Flight Departure Delay Prediction for Airport System Using Deep Learning Method. Aerospace, 12(3), 246. <https://doi.org/10.3390/aerospace12030246>
- [20] Zhao, Z., Feng, S., Song, M., & Liang, Q. (2022). A delay prediction method for the whole process of transit flight. Aerospace, 9(11), 645. <https://doi.org/10.3390/aerospace91106>